

Executive Summary / Ringkasan

Pada bidang akademik yang bergerak cepat, pelajar kesulitan menjaga konsistensi belajar karena kurangnya alat evaluasi diri yang objektif. Sistem EduTrack hadir sebagai platform pemantauan performa akademik berbasis *Machine Learning* untuk memetakan aktivitas harian siswa dan memprediksi kesiapan akademik mereka.

Sistem backend produksi menggunakan model regresi berbasis TensorFlow/Keras untuk memprediksi indeks kesiapan siswa (*Academic Readiness*) yang kemudian diskalakan ke rentang 0–100. Hasil nilai ini diintegrasikan ke antarmuka pengguna (UI) berbasis React.js, di mana tingkat risiko akademik (Tinggi, Sedang, Rendah) ditentukan secara langsung melalui ambang batas tetap (*fixed thresholds*). Strategi intervensi personal dan rekomendasi belajar dihasilkan secara dinamis melalui simulasi skenario *what-if* pada peladen API, membantu siswa mengidentifikasi aspek perilaku yang perlu ditingkatkan secara interaktif.

Problem Discovery

Latar belakang

Performa belajar siswa dipengaruhi oleh kombinasi faktor perilaku, durasi belajar, tingkat kehadiran, serta dukungan lingkungan. Untuk memberikan intervensi yang tepat, diperlukan sistem yang mampu memproyeksikan parameter aktivitas tersebut ke dalam sebuah nilai indikator kesiapan akademik yang terukur dan objektif.

Rumusan masalah

- Bagaimana mengimplementasikan model regresi jaringan saraf untuk memprediksi indeks kesiapan akademik (*Academic Readiness*) secara akurat berdasarkan aktivitas belajar?
- Bagaimana memetakan hasil prediksi kontinu menjadi tingkat risiko yang dapat ditindaklanjuti serta menyusun mekanisme rekomendasi interaktif di sisi peladen?

Tujuan

- Mengembangkan model regresi TensorFlow/Keras untuk memprediksi skor *Academic Readiness* dalam skala 0–100.
- Membangun peladen API yang mampu mensimulasikan skenario perubahan perilaku (*what-if*) untuk menghasilkan rekomendasi perbaikan personal bagi pelajar.

Manfaat

- Memberikan visibilitas instan kepada pelajar mengenai status kesiapan akademik mereka melalui metrik yang terukur.
- Memudahkan proses evaluasi mandiri secara interaktif sehingga pelajar dapat langsung mensimulasikan target perbaikan aktivitas harian mereka.

Business Understanding

Platform ini dirancang untuk menjawab kebutuhan analitis berikut:

1. Bagaimana mentransformasikan data perilaku siswa menjadi prediktor performa kontinu dalam bentuk indeks *Academic Readiness*?
2. Bagaimana mengategorikan tingkat risiko akademik siswa secara efisien di sisi *frontend* menggunakan ambang batas evaluasi yang konsisten?
3. Bagaimana menyediakan fitur intervensi yang adaptif melalui simulasi perubahan parameter input (*what-if*) langsung pada sistem API?

Data Collection

Sumber Data:

- **Fase Analisis:** Dataset `StudentPerformanceFactors.csv` (6.654 baris $\times$ 20 kolom) untuk Exploratory Data Analysis (EDA) dan dashboard internal.
- **Fase Pemodelan Produksi:** Dataset `student_performance_dataset.csv` (6.598 baris $\times$ 25 kolom) yang sudah memuat fitur rekayasa digunakan sebagai rujukan utama untuk *pipeline* pelatihan model pada skrip `main.py`.

Dimensi Data Awal: Terdiri dari 6.654 baris dan 20 kolom yang memuat variabel karakteristik dan perilaku belajar siswa.

Target Model Produksi: Fitur komposit `Academic_Readiness` yang merepresentasikan kesiapan akademik berdasarkan pembobotan nilai masa lalu, motivasi, dan bimbingan belajar.

Exploratory Data Analysis (EDA)

Tahap eksplorasi awal pada notebook analisis berhasil memetakan distribusi karakteristik siswa :

- **Analisis Statistik Deskriptif:** Distribusi skor ujian awal memiliki rata-rata (*Mean*) sebesar 67.24 dan nilai tengah (*Median*) 67.00.
- **Korelasi Fitur:** Ditemukan hubungan positif yang kuat antara jam belajar, tingkat kehadiran, dan skor akademis terdahulu terhadap tingkat kesiapan siswa.

- **Analisis Kesenjangan:** Segmentasi data berbasis kluster performa menunjukkan adanya kesenjangan (*gap*) yang signifikan pada aspek durasi belajar mandiri dan keikutsertaan sesi bimbingan (*tutoring*) antara kelompok siswa.

Data Cleaning & Preprocessing

- **Fase Eksplorasi (Notebook):** Implementasi pembersihan data meliputi penghapusan 56 baris duplikat, pengisian nilai kosong menggunakan metode median untuk fitur numerik (*Sleep_Hours*) dan modus untuk fitur kategorikal, serta eliminasi anomali menggunakan metode *Interquartile Range* (IQR) pada fitur *Hours_Studied* dan *Attendance*. Proses encoding menggunakan metode ordinal dan biner.
- **Fase Produksi (Pipeline Training):** Pada pipeline pelatihan produksi saat ini (*dataset.py*), fungsi pengolahan *clean_data* bertindak sebagai *placeholder* yang belum mengeksekusi kembali langkah-langkah pembersihan otomatis dari notebook. walaupun demikian, pipeline tetap melakukan *preprocessing* minimal berupa pengisian nilai kosong dan penskalaan, dengan menerapkan *median imputer* + *StandardScaler* untuk kolom numerik, serta *constant imputer* + *OneHotEncoder* untuk kolom kategorikal.

Feature Engineering / Feature Extraction

Sistem mendefinisikan 5 fitur rekayasa utama untuk memperkaya representasi data:

1. **Study_Efficiency:** Rasio perbandingan antara jam belajar dengan waktu istirahat harian (*Hours_Studied* / *Sleep_Hours*).
2. **Engagement_Score:** Skor keterlibatan komposit yang merupakan akumulasi nilai dari tingkat keaktifan ekstrakurikuler, pengaruh teman, motivasi, dan aktivitas fisik (bukan perkalian kehadiran dan durasi).
3. **Sleep_Study_Ratio:** Keseimbangan waktu istirahat dan waktu belajar.
4. **Support_Score:** Skor komposit dukungan finansial dan fasilitas belajar.
5. **Academic_Readiness:** Variabel target komposit untuk mengukur kesiapan studi.

Catatan Teknis (*Training-Serving Skew*): Terdapat perbedaan pemodelan formula rekayasa fitur antara kalkulasi di dalam laporan/notebook dengan fungsi inferensi yang tertanam pada skrip produksi *predict.py*. Perbedaan formula komposit ini berpotensi menimbulkan inkonsistensi nilai prediksi saat model diuji pada lingkungan produksi.

Modeling

Arsitektur Model Produksi: Alih-alih menggunakan algoritma klasifikasi berbasis pohon, arsitektur yang diimplementasikan di lingkungan produksi (train.py) adalah model Regresi berbasis TensorFlow/Keras. Model ini mengutilisasi *layer Dense* bertingkat (256→128→64→32→16) dengan *Batch Normalization* dan diakhiri oleh Dense(1, activation='linear')

Mekanisme Inferensi: Model dilatih menggunakan kalkulasi galat *Mean Squared Error* (MSE) untuk memprediksi nilai kontinu *Academic_Readiness*. Pada skrip inferensi predict.py, output dari jaringan saraf TensorFlow tersebut kemudian diproses dan diskalakan ke rentang nilai 0 hingga 100 sebelum dikirimkan ke peluncur aplikasi atau komponen API.

Evaluation

Metrik Evaluasi Tahap Analisis: Evaluasi awal pada lingkungan riset menggunakan perbandingan metrik kesalahan regresi.

Kondisi Pipeline Produksi: Skrip evaluasi otomatis produksi (evaluate.py) memiliki fungsi compute_metrics yang saat ini belum diimplementasikan sepenuhnya. Metrik performa evaluasi klasik seperti *Precision*, *Recall*, *F1-Score* (untuk klasifikasi), maupun pelacakan *Root Mean Squared Error* (RMSE) secara berkala belum terintegrasi aktif di dalam pipeline otomatisasi produksi saat ini.

Result

Prediksi Nilai Kesiapan: Sistem berhasil menghasilkan nilai indeks kesiapan kuantitatif berskala 0–100 melalui endpoint API produksi. Namun dari segi integrasi teknis, respons data pada API saat ini masih menggunakan penamaan kunci lama (*legacy naming*) yaitu predicted_exam_score.

Penentuan Level Risiko di UI: Klasifikasi tingkat risiko siswa tidak diturunkan dari probabilitas model machine learning, melainkan dievaluasi di sisi antarmuka pengguna (Overview.jsx) menggunakan logika batas tetap (*fixed thresholds*), yaitu batasan nilai di bawah 50 dan 75.

Mesin Rekomendasi: Sistem rekomendasi pada komponen api_server.py dijalankan menggunakan mekanisme simulasi skenario *what-if*. Sistem secara dinamis menghitung perubahan output prediksi apabila pengguna menaikkan parameter input tertentu (misalnya menambah jam belajar atau sesi bimbingan), bukan berbasis pada nilai *feature importance* global model.

Teknologi Antarmuka: Layanan prediksi dibungkus menggunakan REST API, didukung oleh visualisasi dasbor analitik Streamlit untuk kebutuhan internal, serta aplikasi web utama berbasis React.js untuk kebutuhan siswa.

Conclusion

EduTrack telah berhasil beralih dari sekadar eksperimen klasifikasi berbasis notebook menjadi sistem produksi berbasis regresi TensorFlow/Keras yang memprediksi indeks *Academic Readiness* siswa. Penentuan tingkat risiko yang efisien menggunakan batas tetap di sisi *frontend* serta mesin rekomendasi interaktif berbasis simulasi *what-if* di peladen API memberikan alat evaluasi diri yang sangat praktis bagi pelajar. Untuk pengembangan berikutnya, sinkronisasi formula fitur antara riset dan produksi (penanganan *training-serving skew*) serta penyelesaian fungsi `clean_data` dan `compute_metrics` pada pipeline produksi menjadi prioritas utama guna menjamin konsistensi jangka panjang sistem.

Lampiran

Dataset

- StudentPerformanceFactors.csv (Dataset mentah untuk kebutuhan EDA & Dasbor)
- student_performance_dataset.csv (Dataset referensi untuk *Training Pipeline*)

Notebook Analisis

- Data_Scientist_Capstone_Project.ipynb (tahapan pembersihan dan EDA)

Model & Pipeline

- main.py (*Entry point* utama penggerak alur *pipeline*)
- dataset.py (Modul *preprocessing* otomatis)
- train.py (Arsitektur regresi dan kompilasi model)
- train_custom_loop.py (Implementasi skema pelatihan *Custom GradientTape*)
- predict.py (Modul *inference* dan penskalaan rentang nilai)
- evaluate.py (Skrip validasi model *post-training*)

API, Deployment & Visualisasi

- api_server.py
- google_ai_client.py
- dashboard.py

Frontend (React)

- Overview.jsx
- WhatIf.jsx